

هدف پروژه

در این پروژه ما قصد داریم تا به کمک الگوریتم ژنتیک توابع ریاضی را تخمین بزنیم. گونه‌های ما در این پروژه درخت محاسبه توابع هستند که نسل به نسل غربال می‌شوند و آن‌هایی که با هدف ما سازگاری بیشتری دارند، به جا می‌مانند.

طراحی گونه

در طراحی درخت‌های توابع، از کلاس Node استفاده شده است، که در ادامه جزئیات طراحی آن را توضیح می‌دهیم. برای اینکه برنامه ما نسبت به طراحی درخت و استفاده از توابع آن منعطف باشد، در ابتدا مفاهیم رئوس را در بالاترین سطح انتزاع کلاس بندی می‌کنیم.

هر راس، قابلیت محاسبه مقدار تابعی که خودش در ریشه آن قرار دارد، را باید داشته باشد. همچنین، فرم نوشتاری تابع مورد نظر را باید برگرداند. میتوان از رئوس انتظار داشت که فرزندانیش و یا تمام زیردرخت مربوط به خودش را برگرداند.

در ادامه دو کلاس برای رئوس تک عملوندی و دو عملوندی طراحی کرده‌ام. رئوس تک عملوندی پوینتر به تنها فرزندشان و رئوس دو عملوندی پوینتر به فرزند چپ و راستشان را نگه می‌دارند.

با کلاس‌های بالا همه شرایط محیاست تا برای تک تک عملگرهای ریاضی از یکی از دو کلاس بالا ارث ببریم. همان‌طور که در کد به جزئیات نوشته شده است، عملگرهای Constant, Parameter, Sinus, Cosinus, جزو عملگرهای Unary و Addition, Subtraction, Multiplication, Division, Power جزو عملگرهای دو عملوندی هستند.

طراحی دیتاست

برای ساخت دیتاست، تابع و بازه‌ای از دامنه را از ورودی می‌گیریم و به تعداد نقاط مشخص شده در بازه مورد نظر از نمودار تابع نقطه برمی‌داریم. با تابع add_dataset می‌توان مجموعه نقاط دو دیتاست را روی هم ریخت و در نتیجه از توابع چند ضابطه‌ای نمونه گیری کرد. اگر تابعی برای دیتاست مشخص نشود، نمونه‌های خود را به صورت تصادفی انتخاب می‌کند.

شیوه گزارش نتایج آزمایش‌ها

به ازای هر آزمایش انجام شده، قطعه کد مربوط به آن قرار داده شده است. همچنین در زیر آن نمودار تغییرات loss توابع در طول نسل‌ها وجود دارد. برای تست کارایی و نزدیکی جواب ما به تابع اصلی، تعداد نقاط زیادی را از نمودار هر دو نمونه برداری کرده‌ایم. نقاط تابع اصلی با رنگ‌آبی و تخمین تابع ما با رنگ نارنجی مشخص شده است. در نمودارهایی که رنگ آبی دیده نمی‌شود، در واقع تابع ما تا حد خوبی به تابع اصلی منطبق است. دقت کنید که بازه‌ای که برای تست انتخاب کرده‌ایم مطابق با رفتار تابع بسیار بزرگتر از بازه یادگیری انتخاب شده است.

طراحی درخت

با توجه به ساختار رئوسی که طراحی کردیم، هر درخت با شناختن ریشه خود و صدا زدن توابع آن، همه اطلاعات خود را خواهد داشت.

اما به عنوان گونه‌ای که باید مورد تکامل قرار بگیرد، باید نحوه جهش Mutation و Breed جفت‌گیری دو نمونه از آن تعریف شود. در ادامه برای هر ساختار درختی که طراحی کرده‌ایم این موارد را مشخص می‌کنیم.

درخت XPolyTree

با الهام گیری از بسط تیلور توابع پیوسته، می‌خواهیم به کمک چندجمله‌ای توابع را تخمین بزنیم. این نوع درخت با داشتن درجه و بازه ضرایب چندجمله‌ای، ساخته می‌شود. ضرایب در آن بازه به صورت یکنواخت نمونه برداری می‌شوند.

• شیوه Breed

در ورودی، دو چندجمله‌ای با درجه برابر خواهیم داشت. فرزند آن‌ها به گونه‌ای تعیین می‌شود که هر ضریب آن با احتمال برابر از یکی از والدین انتخاب می‌شود.

• چالش و نحوه رفع آن

در ابتدا، با توجه به میزان loss دو درخت، میانگین وزن دار ضرایب را می‌گرفتم ولی با توجه به غیریکنوانت بودن loss ها، عملاً تاثیر والدضعیف از بین می‌رفت. سپس با توابع سیگموئید loss را نرمال کردم ولی در این حال هم عملاً برای والدین در یک نسل وزن ضرایب برابر می‌شد. سپس میانگین گیری معمولی را جایگزین کردم. اشکال این روش، در این بود که مجموعه فرزندان قبل از جهش در پوش محدبفضای تشکیل شده توسط والدین قرار می‌گرفت. در نهایت از روش بالا برای جفت‌گیری این درختان استفاده کردم.

• شیوه Mutation

یکی از ضرایب چندجمله‌ای را به صورت تصادفی انتخاب و با مقدار تصادفی کوچکی جمع یا از آن کم می‌کنیم.

• چالش و نحوه رفع آن

در ابتدا برای جهش یک گونه، مقداری تصادفی برای تمام ضرایب آن در نظر می‌گرفتم و آن‌ها را تغییر می‌دادم. اما به تجربه فهمیدم که هرچه تغییرات کوچک‌تر باشد، احتمال پیشرفت و پیدا کردن گونه بهتر، بیشتر خواهد بود.

• آزمایش‌ها

در تست‌هایی که از این شیوه مشاهده کردم، به نظر الگوریتم خیلی هوشمندانه ابتدا ضریبی را تنظیم می‌کرد که در رفتار آن تابع در بازهمشخص شده تاثیر بیشتری داشت.

در آزمایش‌هایی که چندجمله‌ای را تقریب می‌زدیم، تمام ضرایب تا حد خوبی به ضرایب چندجمله‌ای منطبق شده‌اند. در ادامه تابع سینوس را به کمک چندجمله‌ای تقریب زده‌ایم که همان طور که می‌بینید، ضریب هر جمله به سمت بسط تیلور سینوس میل کرده است. برای افزایش دقت، می‌توان تعداد نسل‌ها و یا بازه‌ای که برای یادگیری مشخص می‌کنیم را افزایش دهیم.

درخت ComplexTree

این درخت را با هدف امکان تولید همه توابع ممکن با عملیات‌های گفته شده طراحی شده است. یکی از ایده‌های اصلی در تمام مراحل ساخت این درخت، استفاده از انتخاب‌های تصادفی است. هر جا که از متغیر coin استفاده شده است، در واقع یک تصمیم تصادفی گرفته می‌شود که با توجه به میزان مناسب بودن هر تصمیم، احتمال آن پیشامد را تنظیم کرده‌ام. مزیت استفاده از این شیوه برای تصمیمگیری این است که همه حالت‌های ممکن که بر سر دوراهی قرار می‌گیریم امکان به وجود آمدن خواهند داشت و در صورت نامطلوب بودن نسل بعدی حذف می‌شوند. علاوه بر آن، از یک شکل شدن نسل بعد جلوگیری می‌کند.

• شیوه Breed

در صورت بچه نداشتن، یا با سکه‌ای که می‌اندازیم، بچه تولید شده، یک راس دو عملوندی در بالای ریشه‌های والدین خواهد بود. در صورتی که یکی از والدین بیش از حد پیچیده باشد (بیش از ۱۵ راس)، بچه آن‌ها یکی از دو سمت آن خواهد بود. در غیراین صورت، یکی از دو ریشه را تصادفاً انتخاب می‌کنیم و از هر یک از والدین، یک راس بچه در زیر آن قرار می‌دهیم. باز هم به صورت تصادفی، فرزندان را انتخاب می‌کنیم. البته به این نکته توجه می‌کنیم که فرزندی که از یک ریشه می‌آید، از همان سمت انتخاب شود.

• عناصر سازنده درخت Simplex:

از آنجایی که رئوس اغلب برای تعریف شدن به متغیر و یا عدد ثابت نیاز دارند، کوچکترین اجزای سازنده را به صورت Simplex تعریف می‌کنیم. این اجزا می‌توانند، ثابت، متغیر، سینوس، کسینوس و یا اعمال یک عملگر دوتایی روی یک متغیر و عدد ثابت باشند. مجدداً نحوه انتخاب Simplex تماماً با انداختن سکه‌های ورن دار انجام می‌شود.

• چالش‌ها و نحوه رفع آن:

در ابتدا Simplex ها را درختان با عمق حداکثر سه تعریف کرده بودم ولی با کم پیرو نتیجه قبل، هرچه عناصر و تغییرات ساده تر باشند ساختن به کمک آن‌ها بهتر می‌شود. تابع تقسیم، در اثر جهش ممکن بود مخرجی پیدا کند که به لحاظ پارامتری صفر باشد، احتمال وقوع آن را کم کردم و مخرج را عدد ثابت انتخاب کردم. در توابع تست شده مشکل بالا به وجود نیامد. تابع توان، در صورت ورودی منفی و توان اعشاری، به عدد مختلط منجر می‌شد که آن را از تعریف توان حذف کردم، در توابع تست شده، برنامه به کمک ضرب و استفاده از ضرایب بسط تیلور، آن‌ها را می‌ساخت.

• شیوه Mutation

برای جهش دادن یک درخت، از بالا به صورت تصادفی به سمت عمق می‌رویم. در هر مرحله سکه می‌اندازیم، تا مشخص کنیم پایین ترمی‌رویم یا خیر و سمت پایین رفتن را مشخص کنیم. و یا اینکه راسی برای پایین رفتن وجود نداشته باشد. در نتیجه فرایند بالا، راسی که می‌خواهیم تغییر دهیم، انتخاب می‌شود. اگر راس عدد ثابت بود یا مقدار آن را کمی تغییر می‌دهیم و یا مثل بقیه راس‌ها با آن رفتار می‌کنیم. برای تغییر یک راس، آن را با یک Simplex جایگزین می‌کنیم.

• چالش‌ها و نحوه رفع آن‌ها:

در نتیجه زاد و ولد درختان، فرزندان بزرگتری به وجود می‌آید و به دلیل پیچیدگی محاسباتی الگوریتم کند می‌شد. با اضافه کردن محدودیت پیچیدگی این مشکل برطرف شد.

شیوه تکامل Evolution

الگوریتم تکاملی پیاده‌سازی شده در هر نسل سه روند Selection, CrossOver, Mutation را طی می‌کند تا نسل بعد را بسازد. شرط پایان تکامل یا رسیدن به حداکثر تعداد نسل‌های مشخص شده است و یا پیدا کردن گونه‌ای که loss آن از ۰,۰۰۰۱ کمتر باشد.

• تابع ارزیاب

برای بررسی عملکرد هر درخت از تابع MSELoss روی تمام دیتاست استفاده می‌کنیم. به گونه‌ای که میانگین توان دو فاصله جواب تابع در هر نقطه، تا میزان واقعی محاسبه می‌شود. در نهایت از جواب رادیکال گرفته می‌شود.

• شیوه Selection

ابتدا میزان loss تمام نسل محاسبه می‌شود. سپس افراد بر اساس میزان loss مرتب شده و یک نسبتی از کل آن‌ها selection_ratio که به عنوان پارامتر اجرا مشخص می‌شود، انتخاب می‌شود. در ادامه میزان loss افراد به کمک تابع Sigmoid نرمال سازی می‌شوند.

• شیوه Cross Over

به میزان مشخص شده برای نسل بعد، در هر گام دو والد متناسب با احتمال‌های نرمال شده، انتخاب می‌شوند و تابع Breed آن گونه رویشان صدا زده می‌شود تا فرزندشان برای نسل بعد تولید شود. ممکن است نسبتی از نسل بعد را با گونه‌های ابتدایی پر کنیم، تا از منقرض شدن آن‌ها جلوگیری کنیم.

• شیوه Mutation

روی تمام فرزندان نسل جدید تابع mutation آن گونه صدا زده می‌شود.

جمع بندی و نتایج عملی

در ادامه توابع مختلفی را از برنامه خواسته‌ایم که تخمین بزند و جزئیات هاپر پارامترها و عملکرد برنامه را مشخص کرده‌ایم. ابتدا توابع تک متغیر متفاوت را بررسی کرده ایم. در بین تست‌ها تابع دو ضابطه‌ای و تابع رندوم نیز بررسی شده است. در ادامه برای اینکه قدرت الگوریتم را محک بزنیم، تخمین توابع دو متغیره را بررسی کردیم. جزئیات هر آزمایش در کنار آن مشخص شده است.

نتیجه گیری

منطق اصلی بهبود نسل‌ها، جست‌وجوی شبه تصادفی در بین گونه‌های برتر و حذف گونه‌های ضعیف است. با تکیه بر منطق بالا، هرچه جمعیت اولیه و تعداد نسل‌ها را بیشتر کنیم، احتمال پدید آمدن یک گونه برتر بیشتر خواهد شد. با توجه به تغییراتی که در برنامه دادم، متوجه شدم که هرچه تغییرات و جهش‌ها ساده تر باشند، نسل‌ها با احتمال بیشتری نسبت به نسل قبل خود پیشرفت می‌کنند.

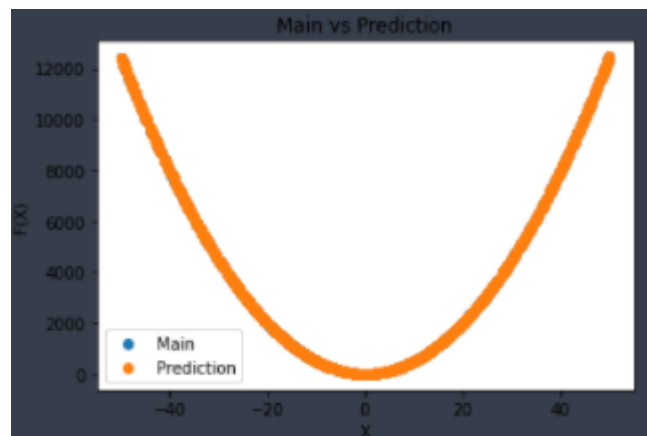
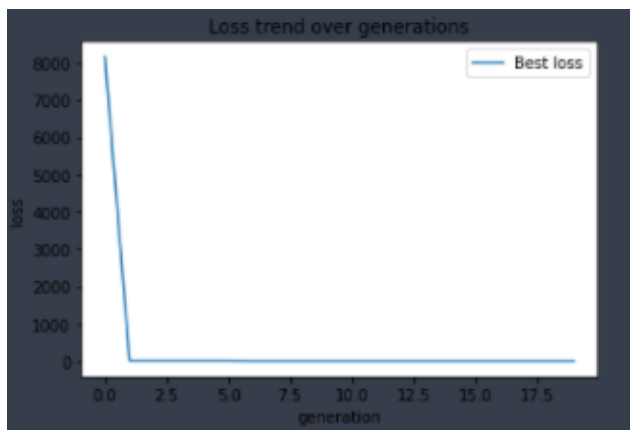
البته بعد از گذشتن نسل‌های زیاد، جمعیت حول گونه برتر متمرکز می‌شود و اگر با جست‌وجوهای محلی نتوان به جواب رسید، الگوریتم قفل می‌شود. برای حل مشکل بالا بهتر است، در صورت گذشت چند نسل و پیشرفت نکردن گونه‌ها، الگوریتم را از ابتدا شروع کنیم تا با یک مجموعه اولیه جدید، شانس پیدا کردن جواب را امتحان کنیم.

$$1: F(x) = 5x^2$$

```
func = Mul(Const(5), Pow(Param(0), Const(2)))
dataset = Dataset(50, mul, 1, (-10, 10))
population = [XpolyTree(2, (3, -3)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, XpolyTree.breed, XpolyTree.mutate)
trainer.evolute(20, 0.4)

trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))
```

Best sample: $5.0 * (x^2) + -0.28 * (x^1) + -1.12$
 Loss: 3.3409722842202147


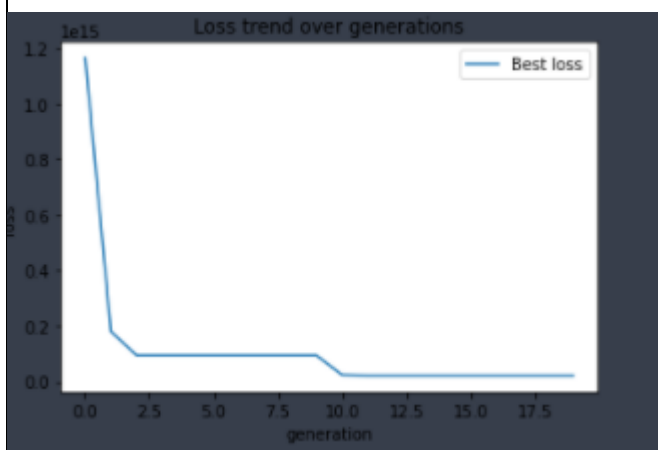


$$2: F(x) = x^4 + 2x^2 - 3$$

```
func = Add(Pow(Param(0), Const(4)), Add(Mul(Const(2), Pow(Param(0), Const(2))), Const(-3)))
dataset = Dataset(100, func, 1, (-100, 100))
population = [XpolyTree(5, (3, -3)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, XpolyTree.breed, XpolyTree.mutate)
trainer.evolute(20, 0.1)

trainer.show_trend()
compare(func, trainer.best_sample, (-500, 500))
```

Best sample: $0.0 * (x^5) + 0.9 * (x^4) + -2.65 * (x^3) + -1.66 * (x^2) + 2.29 * (x^1) + -0.98$
 Loss: 20808208165186.684

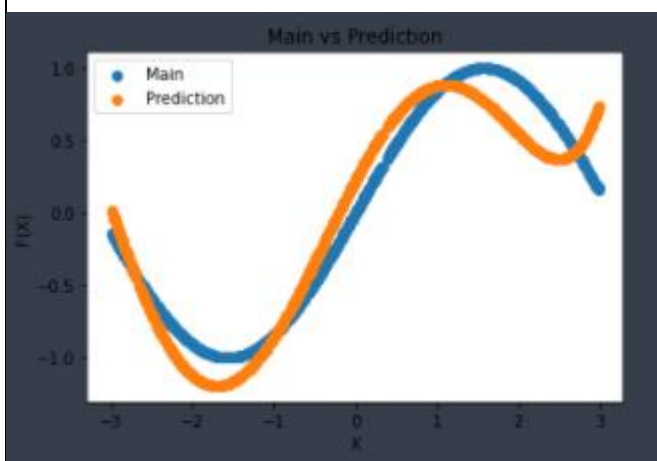
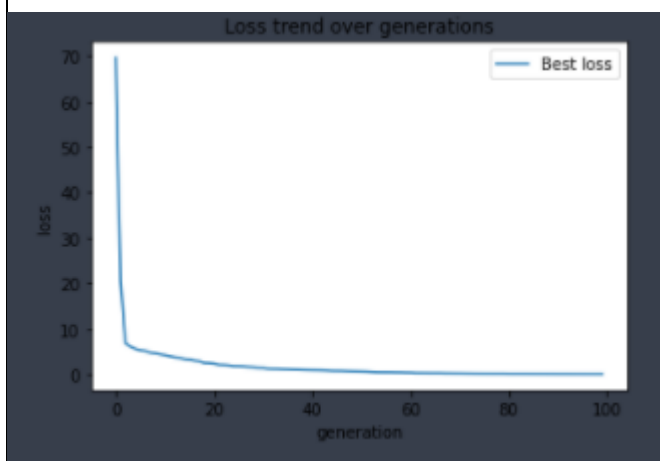


3: $F(x) = \sin(x)$

```
func = Sin(Param(0))
dataset = Dataset(100, func, 1, (-3.14, 3.14))
population = [XpolyTree(5, (3, -3)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, XpolyTree.breed, XpolyTree.mutate)
trainer.evolute(100, 0.1)

trainer.show_trend()
compare(func, trainer.best_sample, (-1, 1))
```

Best sample: $0.01 * (x^5) + 0.03 * (x^4) + -0.21 * (x^3) + -0.25 * (x^2) + 1.06 * (x^1) + 0.23$
 Loss: 0.05115290351814221




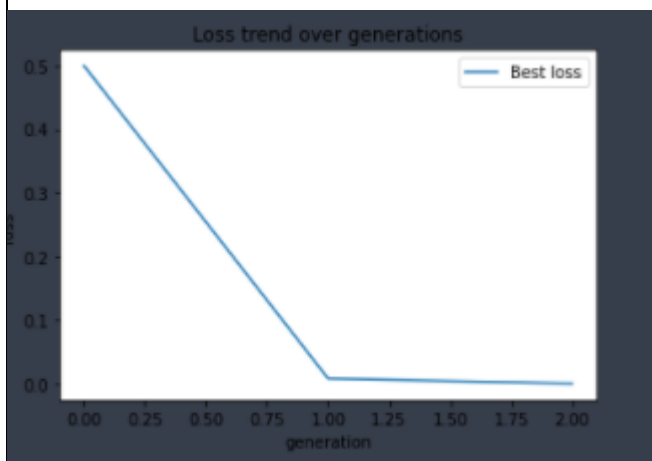
4: $F(x) = \sin(x) + 1$

```

func = Add(Sin(Param(0)), Const(1))
dataset = Dataset(50, func, 1, (-10, 10))
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(20, 0.1)
# trainer.evolute(20, 0.01)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))

```

Best sample: $\sin(-0.96) + 0.91 + \sin(x) + 0.91$
 Loss: 1.0480092049044508e-05



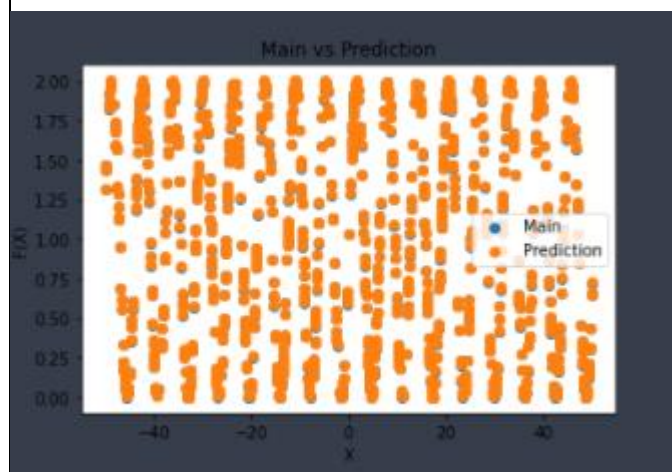

5: $F(x) = \sin(x) + \cos(x)$

```

func = Add(Sin(Param(0)), Cos(Param(0)))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(5, 0.1)
# trainer.evolute(20, 0.01)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))

```

Best sample: $\cos(x - 0.57 + -1.0) + \cos(x)$
 Loss: 5.518427663390709e-07



6: $F(x) = \sin(x)/\cos(x)$

```

func = Div(Sin(Param(0)), Cos(Param(0)))
dataset = Dataset(50, func, 1, (-100, 100))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(1000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.4)
trainer.show_trend()
compare(func, trainer.best_sample, (-500, 500))

```

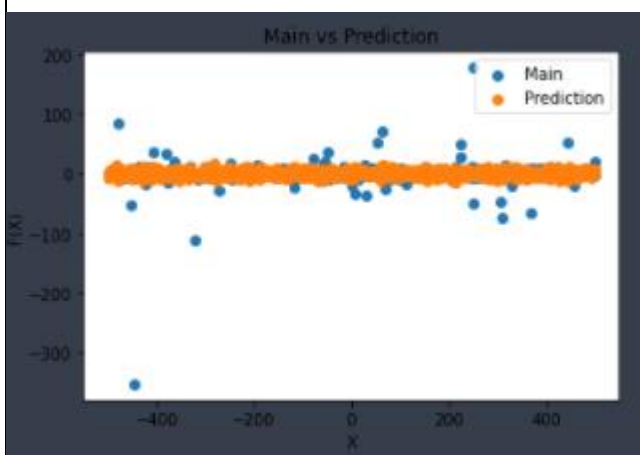

Best sample: $\sin(x * 0.12) + \sin(x) + \sin(x * 0.13) + \sin(x) + \sin(x * 0.13) + \sin(x) + \sin(x * x) + \sin(x)$

Loss: 525.4847904046533

Number of generations: 10

Number of examinations: 4000.0

Execution time: 4.73558497428894


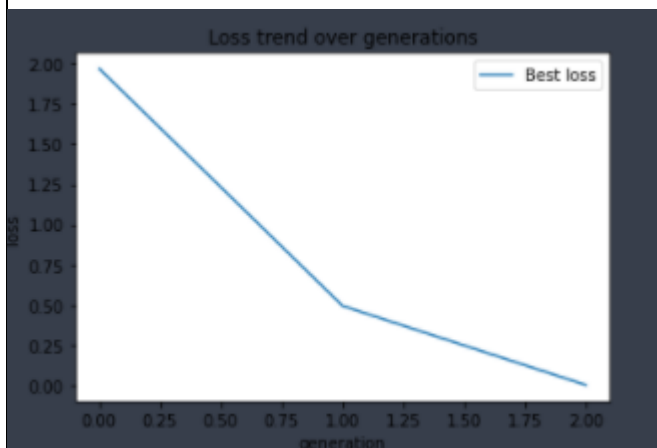


7: $F(x) = x + 2\sin(x)$

```
func = Add(Param(0), Mul(Const(2), Sin(Param(0))))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(20, 0.1)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))
```

Best sample: $x + \sin(x) + 0.0 + \sin(x)$

Loss: 1.3113569160915428e-05



8: $F(x) = x\sin(2x)$

```
func = Mul(Param(0), Sin(Mul(Const(2), Param(0))))
dataset = Dataset(50, func, 1, (-100, 100))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.1)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))
```



Best sample: $(x * \cos(x)) * \sin(x) + (x * \cos(x)) * \sin(x)$

Loss: 2.524354896707238e-29

Number of generations: 1

Number of examinations: 500.0

Execution time: 1.910367727279663



9: $F(x) = 10$

```

func = Const(10)
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(20, 0.1)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))

```

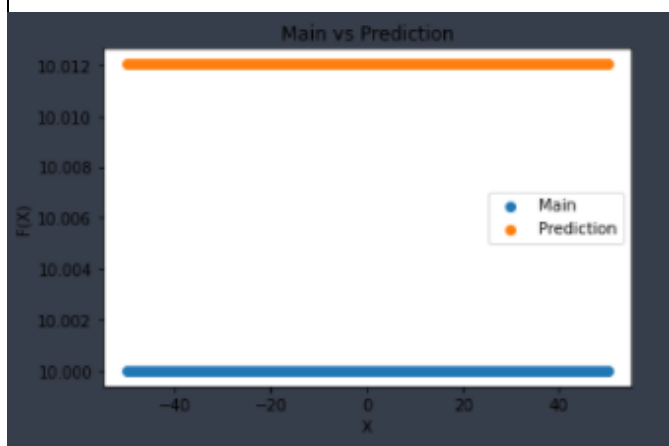
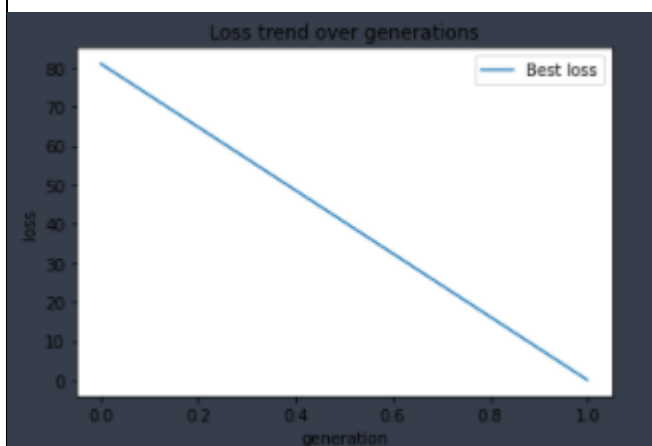
Best sample: 1.0 + 9.02

Loss: 0.00014510096358425276

Number of generations: 3

Number of examinations: 6000.0000000000001

Execution time: 6.697886943817139



10: $F(x) = -200$

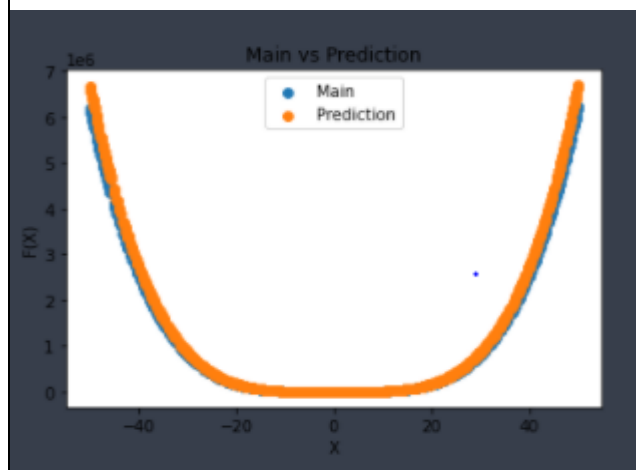

```

func = Const(-200)
dataset = Dataset(50, func, 1, (-100, 100))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(5, 0.4)
trainer.show_trend()
compare(func, trainer.best_sample, (-500, 500))

```

Best sample: $((x - (-0.81 - x)) * (x - 2.03)) * (((x * -0.46) - (0.4 - x)) * (x - -2.34))$

Loss: 6043.995977156814



11: $F(x) = -1/x$



```

func = Div(Const(1), Param(0))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(5000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(5, 0.4)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))

```

Best sample: $1.0 / x$

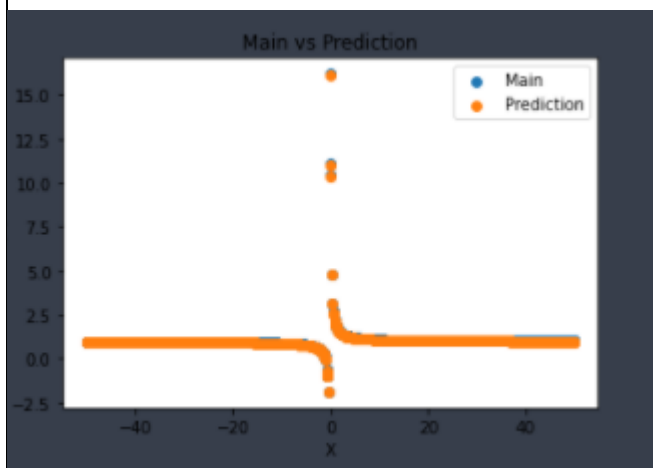

Loss: 1.1599300390642692e-05



12: $F(x) = (x + 1)/x$

```
func = Div(Add(Param(0), Const(1)), Param(0))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))
```

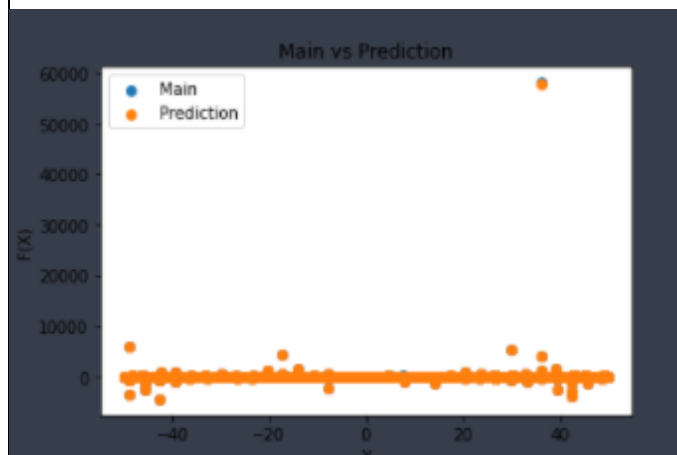
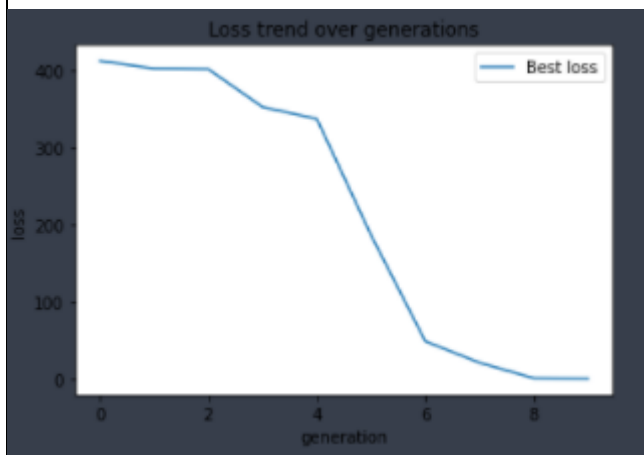
Best sample: $0.97 + 1.0 / x$
 Loss: 0.0007462879218998378



13: $F(x) = (x + 1)/\cos(x)$

```
func = Div(Add(Param(0), Const(1)), Cos(Param(0)))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))
```

Best sample: $(x + 0.86) / \cos(x) + \cos(x) * (\sin(x) + 0.74) + \cos(x) * (x + (-0.89 - x) - -0.62)$
 Loss: 0.7202603019524146



14: $F(x) = x^3$

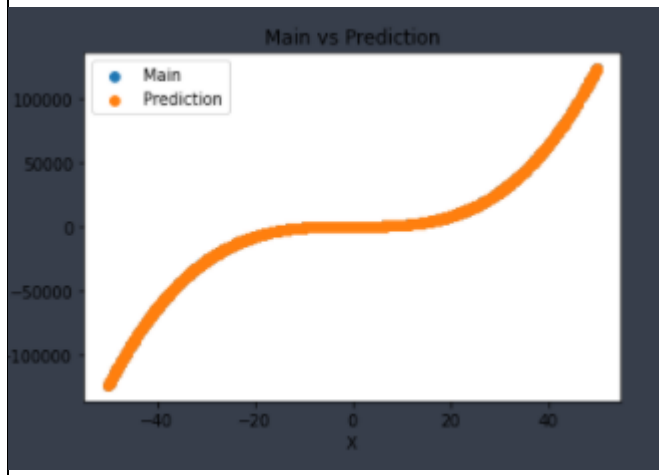
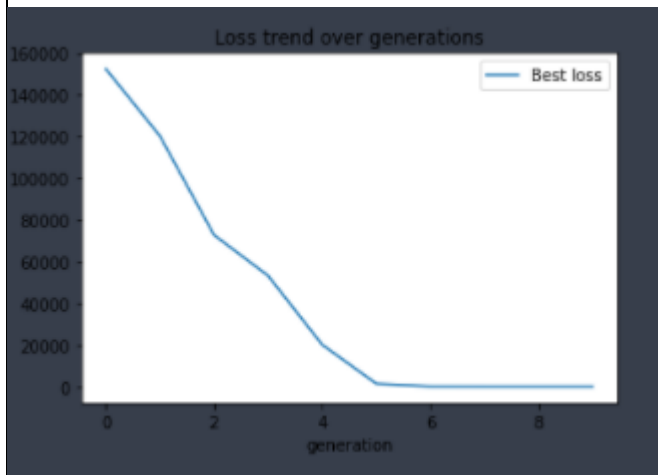
```

func = Pow(Param(0), Const(3))
dataset = Dataset(50, func, 1, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50))

```

Best sample: $((x - 0.85) - -1.95) * ((x * (x + -0.12)) - ((x - 0.95) - -0.07))$

Loss: 4.727760535015854



15: $F(x) = x + y$

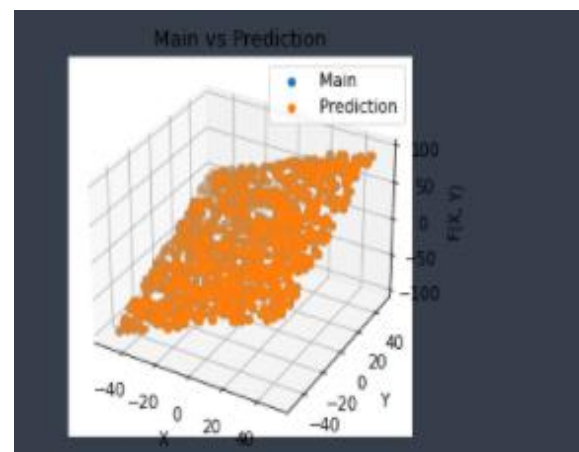
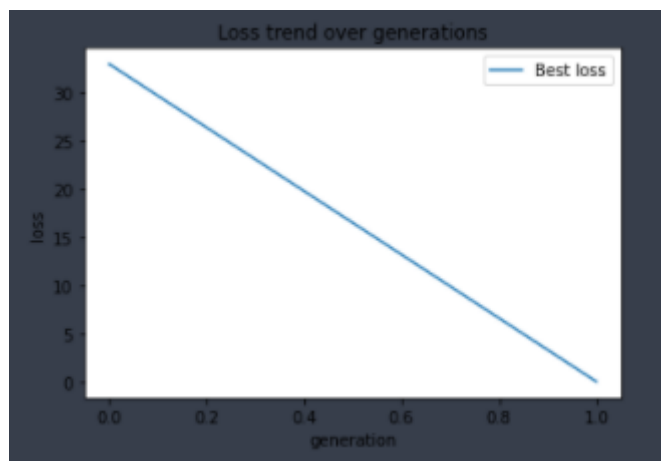
```

func = Add(Param(0), Param(1))
dataset = Dataset(500, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-50, 50))

```

Best sample: $y + x$

Loss: 0.0



16: $F(x) = \sin(x) + y$

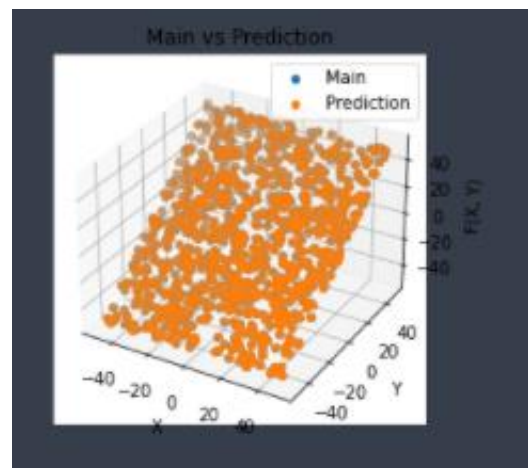
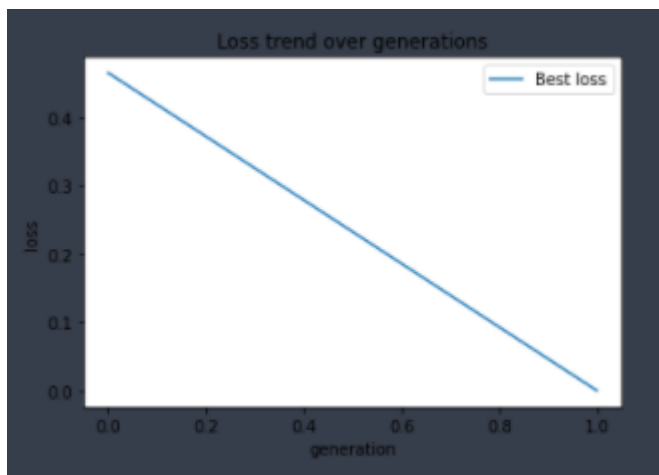
```

func = Add(Sin(Param(0)), Param(1))
dataset = Dataset(500, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-50, 50))

```

Best sample: $\sin(x) + y$

Loss: 0.0



17: $F(x) = \sin(x) + \sin(y)$



```

func = Add(Sin(Param(0)), Param(1))
dataset = Dataset(500, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-50, 50))

```

Best sample: $\sin(x) + \sin(y)$

Loss: 0.0



18: $F(x) = xy + 10$


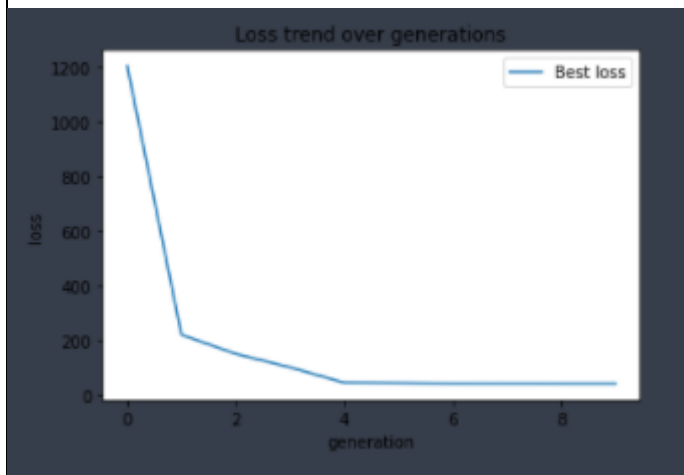
```

func = Add(Mul(Param(0), Param(1)), Const(10))
dataset = Dataset(500, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.3)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-50, 50))

```

Best sample: $(y - ((x - ((x + x * 0.83) * -0.13)) * -0.14)) * (((x - -0.08) - 2.06) - -1.93)$

Loss: 43.864410955905164





19: $F(x) = \sin(x) + \cos(y)$

```
func = Mul(Param(0), Sin(Param(1)))
dataset = Dataset(50, func, 2, (-7, 7))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(15, 0.3, basic_constructor= ComplexTree)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-500, 500))
```

Best sample: $\cos(y) * \sin(x)$



Loss: 0.0



$$20: F(x) = 2.65x + 2.41y$$

```
func = Add(Mul(Const(2.65), Param(0)), Mul(Const(2.41), Param(1)))
dataset = Dataset(100, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(15, 0.3, basic_constructor= ComplexTree)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-500, 500))
```

Best sample: $x + x + -0.66 + y - -1.22 + y - (0.78 - (x * 0.63))$
 Loss: 6.288078134969598


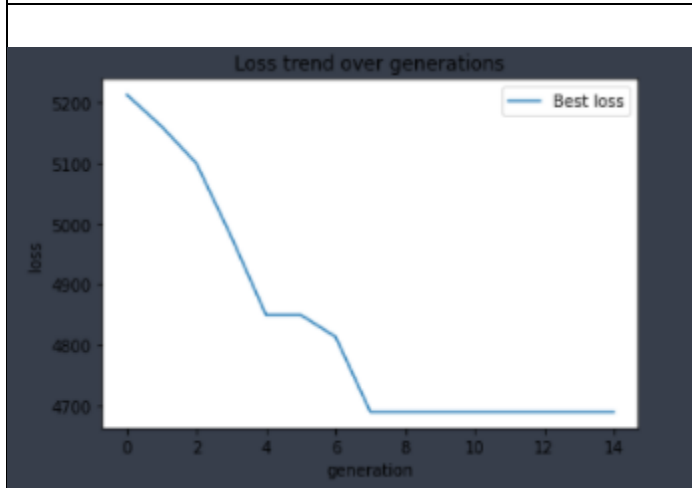


21: $F(x, y) = x + 100\sin(xy)$

```
func = Add(Param(0), Mul(Const(100), Sin(Mul(Param(0), Param(1)))))
dataset = Dataset(100, func, 2, (-10, 10))
data = dataset.point_value[0]
population = [ComplexTree((-2, 2), dim= 2) for _ in range(1000)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(15, 0.3, basic_constructor= ComplexTree)
trainer.show_trend()
compare_3d(func, trainer.best_sample, (-500, 500))
```

Best sample: $((9.55 / (x * (x + 0.8))) - 2.0) * (x - 2.0) + 12.32 / (0.74 - x) + ((1.47 / x) - \sin(x)) * (x - 4.96)$

Loss: 4689.619799997204



$$22: F(x) = \begin{cases} x^2, & -100 < x < -30 \\ -x - 3, & 10 < x < 100 \end{cases}$$

```
func = Pow(Param(0), Const(2))
dataset = Dataset(80, func, 1, (-100, -30))
func = Sub(Sub(Const(0), Param(0)), Const(3))
dataset.add_dataset(Dataset(50, func, 1, (10, 100)))
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(10, 0.1)
# trainer.evolute(20, 0.01)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50), dataset)
```



Best sample: $x * ((x * 0.83) / 1.62) + (x + 3.32) * -37.28$

Loss: 324651.58590126317

Number of generations: 10

Number of examinations: 50

Execution time: 5.611530065536499



23: $F(x) = \text{random function}$

```

func = None
dataset = Dataset(80, func, 1, (-100, 100))
population = [ComplexTree((-2, 2)) for _ in range(500)]
trainer = EvolutionaryTrainer(dataset, population, ComplexTree.breed, ComplexTree.mutate)
trainer.evolute(20, 0.1)
# trainer.evolute(20, 0.01)
trainer.show_trend()
compare(func, trainer.best_sample, (-50, 50), dataset)

```

Best sample: $\cos((x - -0.02) - 0.47) + \cos(x * (-3.92 - x)) + \cos(x - 0.47) + \cos(x * (-0.43 - \sin(x)))$

Loss: 30.732209960584886

Number of generations: 20

Number of examinations: 1000.0

Execution time: 8.258622407913208

